

计算机学院(软件学院)

SCHOOL OF COMPUTER SCIENCE AND ENGINEERING

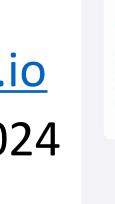
Compilation Principle 编译原理

第0讲:课程介绍、概述

张献伟

xianweiz.github.io

DCS290, 2/27/2024





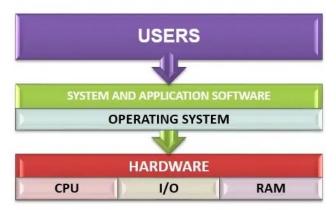
扫一扫二维码, 加入群脚

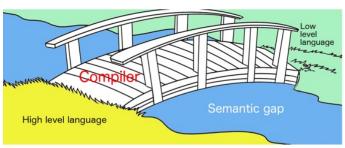
₽QQ

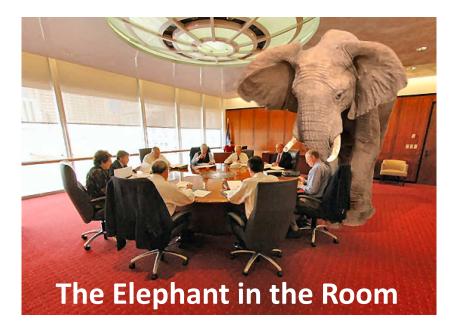


Compiler

- A compiler is system software
 - System software provides platforms for other software
- The elephant in the room
 - People are always use the compiler, but very few are paying much attention to it











Compiler History[编译器的发展]

Compiler origins

- 1952: A-0, term 'compiler' (Grace Hopper)
- 1957: FORTRAN, first commercial compiler (John Backus)
- 1962: LISP, self-hosting and GC (Tim Hart and Mike Levin)
- 1984: GNU Compiler Collection (Stallman)
- 2000: LLVM (Vikram Adve and Chris Lattner)

Turing awards (see <u>link</u>)

- Compiler: 1966, 1987, 2006, 2020
- Programming Language: 1972, 1974, 1977-1981, 1984, 2001, 2003, 2005, 2008

Compilers today

- Modern compilers are complex (gcc has 7M+ LOC)
- There is still a lot of compiler research (LLVM, Pytorch, TVM, ...)
- There are emerging compiler developments in industry





Why Compiler?[为什么要学习编译?]

- 计算机生态一直在改变
 - -新的硬件架构(通用GPU、AI加速器等)
 - 新的程序语言(Rust、Go等)
 - 新的应用场景(ML、IoT等)
- 了解编译程序的实现原理与技术
 - 掌握编译程序/系统设计的基本原理
 - 理解高级语言程序的内部运行机制
 - □ 提高编写和调试程序的能力
 - 培养形式化描述和抽象思维能力
- 大量专业工作与编译技术相关
 - 高级语言实现、软硬件设计与优化、软件缺陷分析
- 硕博士阶段从事与编译相关的研究
 - 尽管可能并不是直接的编译或程序设计方向















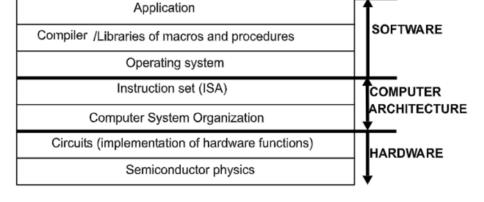


What is Compilation?[什么是编译?]

- 高级语言编写程序,但计算机只理解0/1
 - 自然语言翻译: "This is a sentence" → "这是一个句子"
 - 计算机语言翻译:源程序 > 目标程序
 - 编程人员专注于程序设计,无需过多考虑机器相关的细节
- 不同语言有不同的实现方式
 - "底层"语言通常使用编译 。 C, C++
 - "高级"语言通常是解释性。 Python, Ruby
 - 有些使用混合的方式
 - □ Java: 编译 + 即时编译 (JIT, Just-in-Time)



Bytecode (.class)

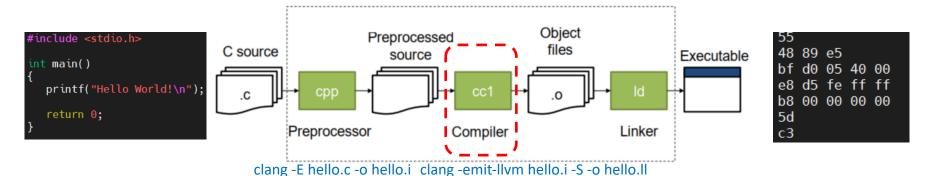




C Compilation[c语言编译]

- 源程序 (hello.c) → 可执行文件 (./hello)
- \$ clang hello.c -o hello \$./hello

- 预处理阶段(preprocessor)
 - □ 汇合源程序,展开宏定义,生成.i文件(另一个C文本文件)
- 编译阶段(compiler)
 - □ .i文件翻译为.s文件(汇编代码)
- 汇编阶段(assembler)
 - **a** .s文件转为.o可重定位对象(relocatable object)文件 (机器指令)
- 连接阶段(linker/loader)
 - □ 连接库代码从而生成可执行(executable)文件(机器指令)

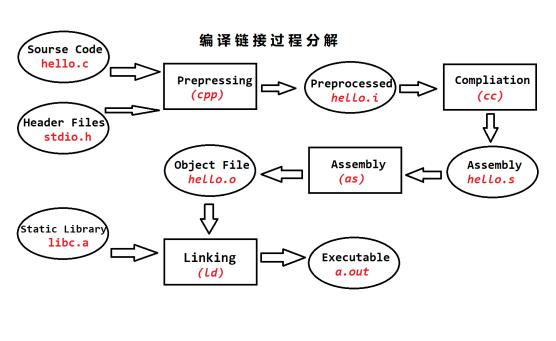


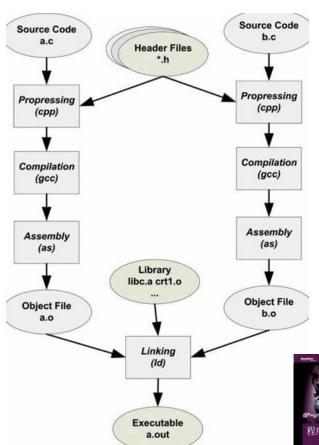




C Compilation (cont.)

- Preprocessing: 源文件→处理后的源文件
- Compiling: 处理后的源文件→汇编代码文件
- Assembling: 汇编代码文件 > 目标文件/机器指令文件
- Linking: 目标文件 > 可执行文件

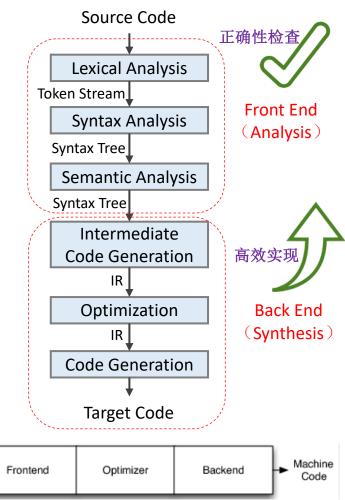






Compilation Procedure[编译过程]

- **前端**(分析): 对源程序,识别语法结构信息,理解语义信息,反馈出错信息
 - 词法分析(Lexical Analysis)
 - 语法分析(Syntax Analysis)
 - 语义分析(Semantic Analysis)
- 后端(综合):综合分析结果,生成语义上等价于源程序的目标程序
 - 中间代码生成(Intermediate Code Generation)
 - Intermediate representation (IR)
 - 代码优化(Code Optimization)
 - 目标代码生成(Code Generation)



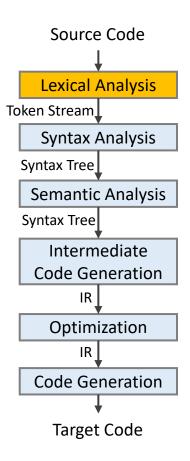




Lexical Analysis[词法分析]

- •扫描源程序字符流,识别并分解出有词法意义的单词或符号(token)
 - 输入:源程序,输出:token序列
 - token表示: <类别,属性值>
 - 保留字、标示符、常量、运算符等
 - token是否符合<u>词法规则</u>?
 - □ Ovar, \$num

```
keyword(for)
                  id(arr)
sym(()
                  sym([)
id(i)
                  id(i)
sym(=)
                  sym(])
num(0)
                  sym(=)
sym(;)
                  id(x)
id(i)
                  sym(*)
sym(<)
                  num(5)
num(10)
                  symbol(;)
sym(;)
id(i)
sym(++)
sym())
                  23
```

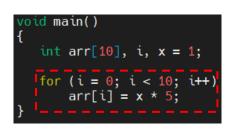


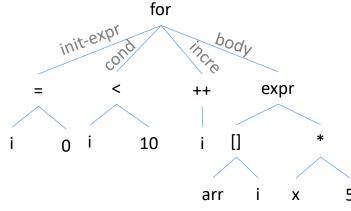


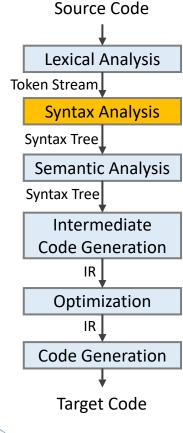


Syntax Analysis[语法分析]

- •解析源程序对应的token序列,生成语法分析结构(syntax tree, 语法分析树)
 - 输入: 单词流,输出: 语法树
 - 输入程序是否符合语法规则?
 - □ X*+
 - a += 5





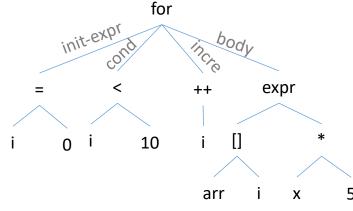


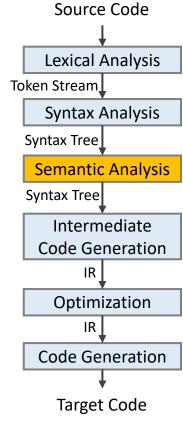




Semantic Analysis[语义分析]

- 基于语法结果进一步分析语义
 - 输入: 语法树,输出: 语法树+符号表
 - 收集标识符的属性信息(type, scope等)
 - 输入程序是否符合语义规则?
 - □ 变量未声明即使用; 重复声明
 - \Box int x; y = x(3);





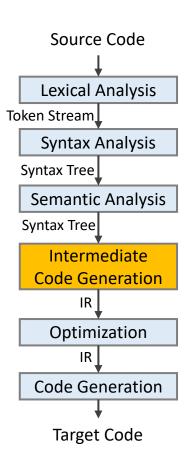




Intermediate Code[中间代码生成]

- 初步翻译,生成<u>等价</u>于源程序的中间 表示(IR)
 - 输入: 语法树, 输出: IR
 - 建立源和目标语言的桥梁,易于翻译过程的实现,利于实现某些优化算法
 - IR形式:通常三地址码(TAC)

```
i := 0
loop:
    t1 := x * 5
    t2 := &arr
    t3 := sizeof(int)
    t4 := t3 * i
    t5 := t2 + t4
    *t5 := t1
    i := i + 1
    if i < 10 goto loop</pre>
```

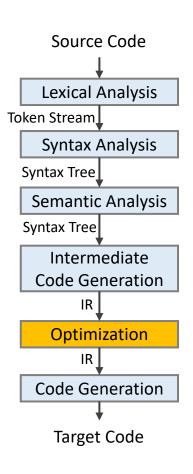






Code Optimization[代码优化]

- •加工变换中间代码使其<u>更好</u>(例如, 代码更短、性能更高、内存使用更少)
 - 输入: IR, 输出: (优化的) IR
 - 机器无关(machine independent)
 - 例如: 设别重复运算并删除;运算操作 替换;使用已知量





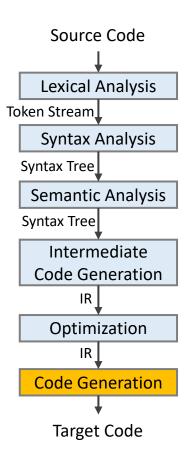


Target Code[目标代码生成]

- 为特定<u>机器</u>产生目标代码(e.g., 汇编)
 - 输入: (优化的) IR, 输出: 目标代码
 - 寄存器分配: 放置频繁访问数据
 - 指令选取:确定机器指令实现IR操作
 - 进一步的机器有关优化
 - □ 例如: 寄存器及访存优化

```
void main()
{
   int arr[10], i, x = 1;
   for (i = 0; i < 10; i++)
       arr[i] = x * 5;
}</pre>
```

```
14: 8b 55 f8
                    mov -0x8(%rbp),%edx
                                                     // edx = x
17: 89 d0
                        %edx,%eax
                                                     // eax = x
                   mov
                                                     // eax = (x << 2)
19: c1 e0 02
                   shl
                          $0x2,%eax
                         %eax,%edx
                                                     // edx = (x << 2) + x
1c: 01 c2
                   add
                          -0x4(%rbp),%eax
                                                     // eax = i
1e: 8b 45 fc
                   mov
21: 48 98
                   cltq
23: 89 54 85 d0
                                                     // arr[i] = 5x
                   mov
                          %edx,-0x30(%rbp,%rax,4)
27: 83 45 fc 01
                   addl
                          $0x1,-0x4(%rbp)
                                                     // i++
2b: 83 7d fc 09
                          $0x9,-0x4(%rbp)
                                                    // i <= 9
                   cmpl
2f: 7e e3
                          14 <main+0x14>
                                                     // loop end?
                   ile
```



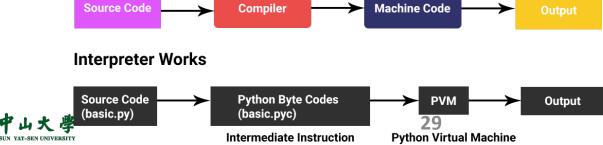


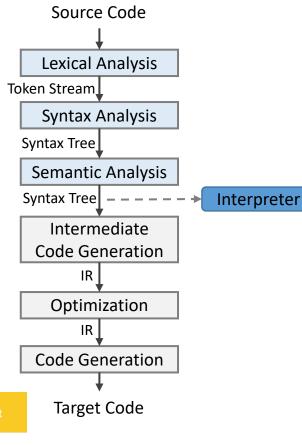


Interpret vs Compile[解释 vs. 编译]

- •编译:翻译成机器语言后方能运行
 - 目标程序独立于源程序(修改 → 再编译 → 运行)
 - 分析程序上下文, 易于整体性优化
 - 性能更好(因此,核心代码通常C/C++)
- 解释:源程序作为输入,边解释边 执行
 - 不生成目标程序,可迁移性高
 - 逐句执行,很难进行优化
 - 性能通常不会太好

Compiler Works

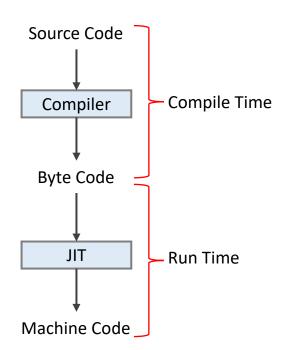






JIT[即时编译]

- 即时编译(Just-In-Time Compiler): 运行时执行程序编译操作
 - 弥补解释执行的不足
 - 把翻译过的机器代码保存起来,以备下次使用
 - 传统编译(AOT, Ahead-Of-Time): 先编译后运行
- JIT vs. AOT
 - JIT具备解释器的灵活性
 - 。 只要有JIT编译器,代码即可运行
 - 性能上基本和AOT等同
 - □运行时编译操作带来一些性能上的损失
 - 但可以利用程序运行特征进行动态优化







Compilation Procedure[编译过程]

- 前端(分析):对源程序,识别语法结构信息,理解语义信息,反馈出错信息
 - 词法分析(Lexical Analysis)词
 - 语法分析(Syntax Analysis) 语句
 - 语义分析(Semantic Analysis) 上下文
- 后端(综合):综合分析结果,生成语义上等价于源程序的目标程序
 - 中间代码生成(Intermediate Code Generation)
 - □ Intermediate representation (IR)转换
 - 代码优化(Code Optimization) 更好
 - 目标代码生成(Code Generation)可执行^{Source}

